

基于无线信道状态信息的跌倒无源监测方法

黄濛濛^{1*}, 刘 军¹, 张逸凡¹, 谷 雨¹, 任福继^{1,2}

(1. 合肥工业大学 计算机与信息学院, 合肥 230601; 2. 德岛大学 信息科学与智能系统系, 日本 德岛 77085020)

(* 通信作者电子邮箱 huangmmeng@mail.hfut.edu.cn)

摘 要:针对传统基于视频或传感器的跌倒检测方法中环境依赖、空间受限等问题,提出了一种基于无线信道状态信息的跌倒无源检测方法 Fallsense。该方法利用普适、低成本的商用 WiFi 设备,首先采集无线信道状态数据并对数据进行预处理,然后设计动作—信号分析模型,建立轻量级动态模板匹配算法以从时序信道数据中实时检测出承载真实跌倒事件的相关片段。大量实际环境下的实验表明, Fallsense 可以实现较高的准确率以及较低的误报率,准确率达到 95%,误报率为 2.44%。与经典 WiFall 系统相比, Fallsense 将时间复杂度从 WiFall 的 $O(mN \log N)$ 降低到 $O(N)$ (N 是样本数, m 是特征数),且准确率提高了 2.69%,误报率下降了 4.66%。实验结果表明,所提方法是一种快速高效的无源跌倒检测方法。

关键词:跌倒检测;信道状态信息;模板匹配;无源监测

中图分类号: TP391.4 **文献标志码:** A

Passive falling detection method based on wireless channel state information

HUANG Mengmeng^{1*}, LIU Jun¹, ZHANG Yifan¹, GU Yu¹, REN Fujie^{1,2}

(1. School of Computer Science and Information Engineering, Hefei University of Technology, Hefei Anhui 230601, China;

2. Department of Information Science and Intelligent Systems, University of Tokushima, Tokushima 77085020, Japan)

Abstract: Traditional vision-based or sensor-based falling detection systems possess certain inherent shortcomings such as hardware dependence and coverage limitation, hence Fallsense, a passive falling detection method based on wireless Channel State Information (CSI) was proposed. The method was based on low-cost, pervasive and commercial WiFi devices. Firstly, the wireless CSI data was collected and preprocessed. Then a model of motion-signal analysis was built, where a lightweight dynamic template matching algorithm was designed to detect relevant fragments of real falling events from the time-series channel data in real time. Experiments in a large number of actual environments show that Fallsense can achieve high accuracy and low false positive rate, with an accuracy of 95% and a false positive rate of 2.44%. Compared with the classic WiFall system, Fallsense reduces the time complexity from $O(mN \log N)$ to $O(N)$ (N is the sample number, m is the feature number), and increases the accuracy by 2.69%, decreases the false positive rate by 4.66%. The experimental results confirm that this passive falling detection method is fast and efficient.

Key words: falling detection; channel state information; template matching; passive detection

0 引言

据世界卫生组织 (World Health Organization, WHO) 2018 年发布的报告指出,跌倒是全球意外死亡的第二大原因,每年造成约 646 000 人死亡^[1]。这个现象引起了学术界和工业界的高度重视,吸引了全球研究人员的极大关注,并成为学术界的研究热点^[2]。当前的主流跌倒检测解决方案根据感知设备可以粗略地分为两类,即基于视觉和基于可穿戴传感器:一般来说,前者如文献[3–5]中探索由摄像机捕获的图像或视频片段直接监测跌倒事件,沈秉乾等^[5]提出了一种基于视频人体运动状态判决的跌倒检测方法,该方法由运动目标检测、目标运动跟踪和目标运动行为识别三部分组成,采用两级

支持向量机 (Support Vector Machine, SVM) 决策的方法实现目标运动行为的识别;而后者如文献[6–8]主要依赖可穿戴或环境传感器,通过感知环境突变,如地板振动^[6]等特定特征来识别跌倒。Mostarac 等^[7]使用三轴加速度计和 ZigBee 收发器检测患者跌倒的患者监测和跌倒检测系统。该系统由数据采集、跌倒检测和数据库组成,三轴加速度计用于人体位置跟踪和跌倒检测。该系统能够实时监测患者。

此外,随着现代社会中智能手机越来越普及,一部分研究人员把目光转向于文献[9–10]中那些集成了各种传感器且随身携带的智能设备作为跌倒检测的装置。王忠民等^[10]提出了一种基于时间序列分析异常数据的跌倒监测方法,该方法对手机加速度信号进行时间序列分析,通过计算相邻时间

收稿日期: 2018-09-19; 修回日期: 2018-11-26; 录用日期: 2018-11-26。

基金项目: 国家自然科学基金资助项目 (61772169, 61432004, 61502140); 国家重点研发计划项目 (2018YFB0803403); 中央高校基本科研专项资金资助项目 (JZ2018HGPA0272); 江苏省物联网重点实验室开放项目 (JSWLW-2017-002)。

作者简介: 黄濛濛 (1995—), 女, 安徽六安人, 硕士研究生, 主要研究方向: 情感计算、跌倒监测; 刘军 (1978—), 男, 江苏新沂人, 副教授, 博士, CCF 会员, 主要研究方向: 机器学习加速、计算机体系结构; 张逸凡 (1993—), 男, 安徽合肥人, 硕士研究生, 主要研究方向: 情感计算、机器学习; 谷雨 (1986—), 男, 安徽庐江人, 教授, 博士, CCF 高级会员, 主要研究方向: 情感计算; 任福继 (1959—), 男, 四川南充人, 教授, 博士, 日本工程院院士, 主要研究方向: 情感计算、智能机器人。

窗口之间的相关系数来检测异常数据,利用分类器算法对疑似跌倒行为与真实跌倒行为的异常数据样本进行分类。关于基于视觉和基于传感器的跌倒检测的研究取得了一定的实质性进展。然而,最近的研究揭示了文献[11-16]中的一些固有局限性,例如可扩展性(专用或昂贵的硬件)、覆盖范围(照明/视线约束)和隐私问题(过度监控),因此,研究人员正在努力对传统方法进行改进。

在本文中,提出了一个问题,是否可以构建一个如下的跌倒监测系统:1)在没有特殊硬件的要求下自动准确地监控人的状态并识别跌倒;2)对用户来说是非侵入性和非接触式的;3)可以在各种环境中稳定地工作,包括场景、照明条件等。为此,本文设计了一种利用商用 WiFi 设备的无线信道数据驱动跌倒监测系统。与传统的跌倒监测解决方案相比,这种方法具有几个显著优势:首先,它是一个建立在现有的 WiFi 设备上低成本的系统;其次,它对用户是透明的,不会引起隐私或安全问题,特别适合儿童和老人;最后,它提供了更高的覆盖率,同时对环境条件依赖很少。

本文利用普通、低成本的商用 WiFi 设备,采集无线信道状态数据(Channel State Information, CSI),设计动作—信号分析模型,建立轻量级动态模板匹配算法以从时序信道数据中实时检测出承载真实跌倒事件的相关片段。而当前主流经典算法如 WiFall^[14]、RTFall^[16]大都依赖于大容量训练样本和复杂的分类器如隐马尔可夫模型(Hidden Markov Model, HMM)和 SVM,导致两个主要问题:对静态优化训练集的依赖,以及随之而来的高计算复杂度,因此,本文利用普通、低成本的商用 WiFi 设备,采集无线信道状态数据,构建动作—信号分析模型,设计在线更新的小型简单训练集动态模板匹配(Dynamic Template Matching, DTM)算法,便可从时序信道数据中实时检测出承载真实跌倒事件的相关片段。通过这种方式,不仅可以优化其性能,还可以显著降低整体复杂性。

本文方法将时间复杂度从经典系统 WiFall 的 $O(mN \log N)$ 降低到 $O(N)$ (N 是样本数, m 是特征数),且通过与其在实际场景下的对比实验发现,准确率提高了 2.69%,误报率下降了 4.66%。实验结果表明,本文方法是一种快速、高效的无源跌倒检测方法。

1 基于 CSI 的无源跌倒监测方法

本文提出了一种基于无线信道状态信息的跌倒无源监测方法,其核心思想是采集 CSI,设计动作—信号分析模型,建立轻量级动态模板匹配算法以从时序信道数据中实时检测出承载真实跌倒事件的相关片段。该方法主要分为数据预处理、模板提取、动作识别三个模块,其系统结构如图 1 所示。

1.1 前期实验与分析

在本团队之前搭建的基于 WiFi 的动作识别系统 MoSense^[17]基础上,建立了一个原型系统来分析跌倒以及其他日常动作是如何影响 WiFi 信号的。

1.1.1 信道状态信息

目前可作为信道响应的无线数据包含两种:一种是表示接受功率强度的 RSS(Received Signal Strength),另外一种是指信号衰减的信道状态信息(CSI)。

RSS 描述了所有路径的总接收功率,可以表示为:

$$RSS = 10 \lg(\|\mathbf{H}\|^2) \quad (1)$$

式(1)中 $\mathbf{H} = \sum_{k=1}^N \|\mathbf{H}_k\| e^{j\theta_k}$, 其中 $\|\mathbf{H}_k\|$ 和 θ_k 分别是第 k 个路径的振幅和相位。由式(1)可以看出 RSS 是粗粒度的,无法描述多径效应,因此,能更好地捕捉多径信道特性的物理层 CSI 成为一种更有效的替代方案。

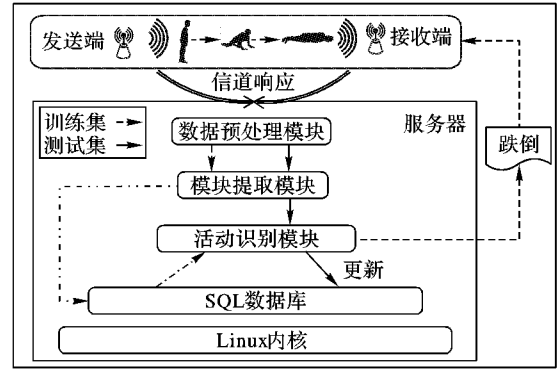


图1 系统结构

Fig. 1 System architecture

在正交频分复用系统(Orthogonal Frequency Division Multiplexing, OFDM)中, $H(f, t)$ 是以 CSI 格式表示的信道频率响应(Channel Frequency Response, CFR)复值。子载波在 t 时刻 f 频率的振幅和相位表示信道性能。可以表示为:

$$H(f, t) = \sum_{k=1}^N h_k(f, t) e^{-j\theta_k(f, t)} \quad (2)$$

其中: h_k 是衰减特征的振幅, $e^{j\theta_k(f, t)}$ 是第 k 个路径上由传播延迟造成的相位偏移。

1.1.2 前期实验分析

原型系统 如图 2 所示,原型系统由两台配有 Intel 5300 网卡(5 GHz)的微型计算机组成。其中一台外接了一根天线作为发送端,另外一台外接了三根天线作为接收端。天线均被固定在三脚架上,采样频率为 1000 Hz。




图2 原型系统的实物图和实验环境

Fig. 2 Physical map of prototype system and layout of experimental environment

参试人员 考虑到跌倒实验的潜在危险性,招募了一个成年男性进行初期实验。

实验环境 实验在 7 m × 10 m 的办公室进行,办公室里面有椅子、沙发、电脑桌、书柜等家具,实验期间,其他学生也在同一房间里。

动作 本文选取了 4 个可能跟跌倒混淆的类似动作(坐下、站起、躺下、下蹲),实验区空置作为基准参照。

实验设置 如图 2 左上角所示,这三个椭圆表示发送与接收端的感知区域(即非涅尔区域),参试人员应该在区域内

进行实验。发送天线与接收天线的水平距离设置为 1.2 m, 在实验过程中利用理论分析菲涅尔区域 (Fresnel Zones), 利用文献[18]中公式计算最优实验区域, 并结合实验经验, 由于实验动作的幅度范围较大, 在水平距离为 1.2 m 的情况下, 实验动作会穿过最优区域; 因此在这样的实验设置下, 实验效果稳定且细节完备。菲涅尔区域如图 3 所示, 计算的区域半径如表 1 所示 (表中为截取的最优区域菲涅尔区序号)。




图 3 菲涅尔区域
Fig. 3 Fresnel zones

表 1 菲涅尔区域
Tab. 1 Fresnel zone

菲涅尔区序号	总区域半径/cm	半区域半径/cm
8	39.80	2.78
9	42.45	2.65
10	45.00	2.55
11	47.46	2.46

要求参试人员每个动作做 10 次, 得到两个重要的实验结论:

1) 人体运动确实会影响信道响应, 相同运动遵循一定的模式。图 4 为根据跌倒实验的 CSI 振幅值三条流可视化热图

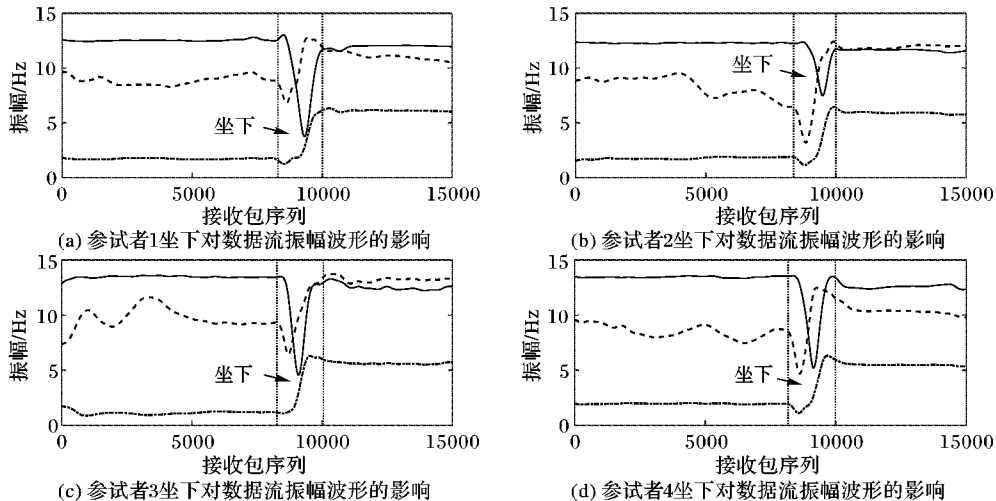


图 5 不同人坐下存在的固定模式
Fig. 5 Certain pattern for sitting down of different people

1.2 数据预处理

由于收集到的原始信道数据可能包含由背景噪声或硬件故障造成的异常样本, 因此首先要对原始数据进行过滤。在数据预处理模块里面, 选择巴特沃斯 (Butterworth) 滤波器。当以 $F_s = 1000 \text{ sample/s}$ 的速率采样 CSI 数据时, 将巴特沃斯滤波器的截止频率 ω_c 设为 $(2\pi \cdot f)/F_s = 0.0942 \text{ rad/s}$ 。

图, 在 8000 ~ 10000 的接收包序列之间, 参事人员跌倒, 可以看出跌倒会对信道数据造成显著影响。图 5 为 4 次坐下实验各自经过平均每条数据流上 30 个子载波得到的振幅波形, 可以看出, 对于同一个人, 同样的动作有着相似的波形趋势。




图 4 跌倒对信道数据的影响
Fig. 4 Impact of falling on channel data

2) 不同的人体运动对信道数据的影响是不同的。图 6 所示, 图中 3 条数据流的振幅值是经过平均 30 条子载波得到的。可以看出, 不同动作的波形模式存在明显差异, 且对数据流 1 造成的影响是类似脉冲, 对数据流 2 的影响则是状态的变化。通过以上实验说明, 人类运动确实会影响信道数据而且不同的动作有着不同的影响。这些观察结果促使开发一种基于模式的跌倒监测系统, 下一节, 将详细介绍系统设计。

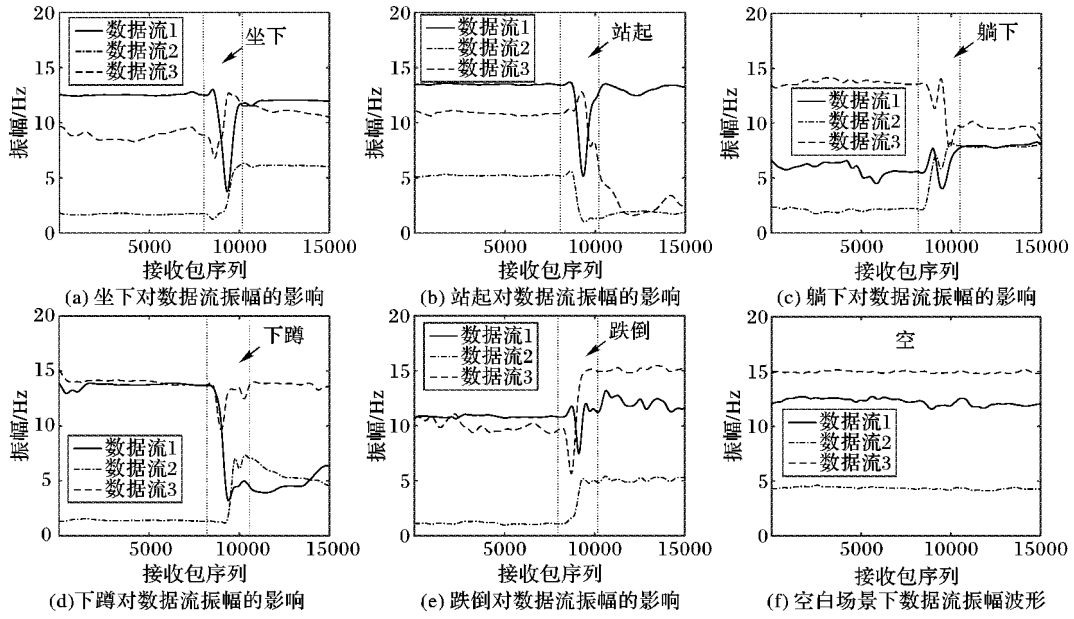


图6 六种动作对信道信息的影响

Fig. 6 Impact of six actions on channel data

1.3 跌倒检测

1.3.1 模板提取模块

预处理之后的数据,被送入模板提取模块,通过该模块训练数据提取出不同动作的标准模板库。虽然不同动作的 CSI 信号指纹有着较大的可区分差异,问题在于不同的人执行同一动作存在着一定差异,因为体型和个人习惯的不同会导致身体表达的多样性。显然,最好的方法是给每个人的每个动作维护一个单独的模板,但是算法复杂度也会因此增加。为此本文设置了一个参数 C_{thr} , 以实现算法复杂性与性能之间的权衡。

假设有 K 个参试者,则第 K 个参试者执行某个动作 $i(i \in [1, M])$ 的次数为 n_i 。将这 n_i 个某动作的数据平均得到一个模板,这样就拥有了每个动作的 K 个模板。如果将这 K 个模板都作为单独的模板加入模板库,那算法的性能应该是最高的,但是相应的算法复杂度也是最高的。因此进一步对这 K 个模板进行简化分组。将每个组的模板平均为一个核心模板,然后计算第 k 个模板与核心模板的欧氏距离,如下所示:

$$d = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2} \quad (3)$$

此处 $X = \{x_1, x_2, \cdots, x_n\}$, $Y = \{y_1, y_2, \cdots, y_n\}$ 表示两条 CSI 数据流, d 是它们之间的欧氏距离。

将所有的 d_k 求和得到 D , 用以评估不同人同一动作物理表达的多样性:

$$D = \sum_{k=1}^K d_k \quad (4)$$

计算出所有的分组方式知道 D 小于权衡值 C_{thr} 。一般来说, C_{thr} 越小,模板库规模就越大,导致准确率越高,相应的复杂度也会越高。

1.3.2 动作识别模块

这个模块用于动作识别。计算测试集 CSI_{test} 与模板库的欧氏距离,找到最接近的标准模板,然后输出对应的动作类型。如果这个测试集数据流比它在标准语料库中的某个数据

流更好,将用这个测试集数据流替换最坏的模板来更新标准语料库,由此建立了动态的模板库。比如说,拿到一个动作的数据,首先计算这个动作跟搭建好的模板库中标准模板的欧氏距离,比较几个欧氏距离,把这个动作归类到欧氏距离最小的动作类型,此处假设为跌倒。如果该动作与标准模板的欧氏距离比跌倒标准模板库中某个跌倒数据与标准模板的欧氏距离还要小,那就用该跌倒动作的数据替换之,并平均跌倒标准模板库得到新的跌倒标准模板。

1.3.3 复杂度分析

对算法复杂度进行分析。由于识别过程决定了整个系统的复杂性,得出以下结论:本文算法的计算复杂度为训练的 $O(N)$ 和测试的 $O(t \cdot N)$, 其中 N 和 t 分别代表训练集和标准模板库的大小。

证明 模板提取模块中直接对 N 个样本进行处理,因此,它的复杂性是 $O(N)$ 。动作识别模块将 N 个样本与 t 个标准模板进行比较,因此计算复杂度为 $O(t \cdot N)$ 。总体复杂度为 $O(t \cdot N)$ 。

2 实验结果分析与评估

2.1 评估设置

原型系统、实验环境、实验设置均 1.2 节中保持一致。

参试人员 招募了 8 名参与者(其中有 2 名女性),年龄从 21 ~ 26 岁不等。

动作 与 WiFall^[14] 相同,本文选择了 4 种类似跌倒的动作,即坐下、站起、躺下和下蹲。

评估标准 与 WiFall 相同,采用准确率(P)和误报率(即假阴性率(False Negative Rate, FNR))来描述系统的性能,计算公式如下:

$$P = \frac{\# \text{真阳性}}{\# \text{真阳性} + \# \text{假阳性}} \quad (5)$$

$$FNR = \frac{\# \text{假阴性}}{\# \text{真阴性} + \# \text{假阴性}} \quad (6)$$

进一步定义了 P_5 和 P_2 , 分别表示识别 5 种动作和 2 种动作的监测精度: P_5 即正确预测坐下、站起、躺下、下蹲以及跌倒这五个动作的总和除以整个测试集; 而 P_2 是正确预测跌倒以及其他非跌倒动作的总和除以整个测试集。

$$P_5 = \frac{\text{五种动作正确预测数}}{\text{测试集}} \quad (7)$$

$$P_2 = \frac{\text{正确预测跌倒数或非跌倒数}}{\text{测试集}} \quad (8)$$

数据集 要求每个参与者进行非跌倒动作 10 次, 跌倒动作 20 次, 因此, 该数据集由 $8 \times 4 \times 108 \times 20 = 480$ 个数据组成。每个数据是一个 3 (流: 接收天线数) \times 30 (子载波数) \times 3000 (数据包, $3 \text{ s} \times 1000 \text{ Hz}$) 的矩阵。

2.2 参数对性能的影响

研究不同的系统参数对性能的影响。当为每个动作设置一个模板时, 采用静态模板库的准确率为 60%, 采用动态更新模板库的准确率为 60.42%。当为每个动作设置八个模板时, 采用静态模板库的准确率为 94.17%, 采用动态模板库的准确率为 94.58%。

表 2 准确率混淆矩阵

Tab. 2 Precision confusion matrix

类别	动作	坐下/%	站起/%	躺下/%	下蹲/%	跌倒/%
静态模板库 & 模板数为 1	坐下	40.0	7.50	7.50	10.00	35.00
	站起	7.5	77.50	7.50	5.00	2.50
	躺下	7.5	12.50	65.00	0.00	15.00
	下蹲	5.0	0.00	12.50	77.50	5.00
	跌倒	0.0	18.75	10.00	21.25	50.00
动态模板库 & 模板数为 1	坐下	40.0	10.00	7.50	15.00	27.50
	站起	2.5	80.00	7.50	7.50	2.50
	躺下	0.0	17.50	45.00	7.50	30.00
	下蹲	5.0	10.00	10.00	70.00	5.00
	跌倒	2.5	13.75	7.50	12.50	63.75
静态模板库 & 模板数为 8	坐下	97.5	2.50	0.00	0.00	0.00
	站起	2.5	92.50	2.50	2.50	0.00
	躺下	0.0	2.50	92.50	0.00	5.00
	下蹲	0.0	0.00	7.50	92.50	0.00
	跌倒	0.0	1.25	3.75	0.00	95.00
动态模板库 & 模板库为 8	坐下	97.5	2.50	0.00	0.00	0.00
	站起	2.5	92.50	2.50	2.50	0.00
	躺下	0.0	2.50	92.50	0.00	5.00
	下蹲	0.0	0.00	5.00	95.00	0.00
	跌倒	0.0	1.25	3.75	0.00	95.00

静态模板库 & 模板数为 1 该设置为不更新模板库, 只为每个动作保留一个模板。表 2 显示了相应的混淆矩阵。正如前面提到的, 对于不同参与者执行的相同动作, 信道数据存在一定的差异。因此, 本实验的 P_5 只有 60%, P_2 为 73.75%。

动态模板库 & 模板数为 1 该设置为不断更新动作模板库, 但每个动作只保留一个模板。表 2 显示了相应的混淆矩阵。 P_5 为 60.42%, P_2 为 76.67%。由于模板库的更新, 与第一种设置相比有着一定的改进。但是这种改进很微小, 因为受限于每个动作只有一个模板。这一结果证实, 对所有参与者仅使用一个模板是不够的。换言之, 由于体型和习惯, 不同的人执行相同的动作对信道数据的影响是有差异的。

静态模板库 & 模板数为 8 该设置为不更新动作模板

库, 而为每个动作保留 8 个模板 (8 个参与者)。表 2 显示了相应的混淆矩阵。 P_5 达到 94.17%, P_2 为 97.5%。与前两种设置相比, 系统性能有了明显的提高。这一结果表明, 动作模板库越大, 性能就越好。

动态模板库 & 模板库为 8 该设置为不断更新动作模板库, 并为每个动作保留 8 个模板 (8 个参与者)。表 2 显示了相应的混淆矩阵。 P_5 达到 94.58%, P_2 为 97.5%。与以前的设置相比, 存在一定的性能改进。与本文先前的分析一样, 从系统性能角度看, 这是系统的最佳设置。

2.3 性能对比

为了进一步验证本研究的监测系统, 本文实现了利用 SVM 分类的 WiFall2013^[13] 和利用随机森林的 WiFall2017^[14] (改进版), 并在相同的实验设定下与本文算法进行了比较, 本文算法明显优于 WiFall, 虽然 2017 版本的 WiFall 的准确率相比较于其 2014 版本有所提高, 但是它的误报率也急剧上升了。本文算法相比较于最新的 WiFall2017, 在 WiFall 的基础上准确率有所提高的情况下, 将误报率也控制在一个较低的水平。

表 3 比较了本文算法与 WiFall 的准确率、误报率以及算法复杂度, 表中的 m 、 n 、 t 分别表示特征数、样本数以及模板数。可以看出在这三个层面上本文算法都是更为优秀的。

表 3 本文算法与 WiFall 性能对比

Tab. 3 Performance comparison between the proposed method and WiFall

算法	P/%	FNR/%	算法复杂度 (训练)	算法复杂度 (测试)
WiFall2014	91.86	1.39	$O(m^2 n^2)$	$O(m^2 N)$
WiFall2017	92.31	7.10	$O(m^2 N \log N)$	$O(mN \log N)$
本文算法	95.00	2.44	$O(N)$	$O(tN)$

总结 本实验研究不仅证明了采用模板匹配方法进行跌倒监测的可行性, 而且证明了能够实时工作。可以得出结论, 本文算法是一种低开销但高效的跌倒监测系统, 因此在现实环境中具有潜在的应用价值。

3 结语

本文提出了一种基于 WiFi 的跌倒监测系统, 与其在计算机视觉和可穿戴传感器方面的竞争对手相比, 本文算法有着三个显著的优点: 第一, 它是建立在现成的 WiFi 基础设施之上的低成本系统; 第二, 它对用户是透明的, 不引起隐私或安全问题; 最后, 它提供了更好的覆盖, 而很少依赖于环境条件。实验结果表明, 本文算法的性能优于 WiFall, 在检测精度、误报率和复杂度方面都有很大的优势。

本文算法有几处需要进一步关注的点。比如: 现有的基于模板的跌倒监测算法是粗粒度的, 因为它将跌倒看作一个单一的运动而不是一个复合的运动; 另外, 系统评估需要对系统参数和评估场景进行扩展。

参考文献 (References)

- [1] WHO. Falls [EB/OL]. [2018-01-16]. <https://www.who.int/news-room/fact-sheets/detail/falls>.
- [2] ZHANG Z, CONLY C, ATHITSOS V. A survey on vision-based fall detection[C]// Proceedings of the 8th ACM International Confer-

- ence on Pervasive Technologies Related to Assistive Environments. New York: ACM, 2015: Article No. 46.
- [3] RITA C, ANDREA P, ROBERTO V. A multi-camera vision system for fall detection and alarm generation[J]. *Expert Systems*, 2010, 24(5): 334–345.
- [4] NUNEZ-MARCOS A, AZKUNE G, ARGANDA-CARRERAS I. Vision-based fall detection with convolutional neural networks[J]. *Wireless Communications & Mobile Computing*, 2017, 2017: Article ID 9474806.
- [5] 沈秉乾, 武志勇, 贺前华, 等. 人体姿势状态判决的跌倒检测方法[J]. *计算机应用*, 2014, 34(S1): 223–227. (SHEN B Q, WU Z Y, HE Q H, et al. Fall detection method for human posture state judgment[J]. *Journal of Computer Applications*, 2014, 34(S1): 223–227.)
- [6] 李雷, 张帆, 施化吉, 等. 穿戴式跌倒检测中特征向量的提取和降维研究[J]. *计算机应用研究*, 2019, 36(1): 103–105. (LI L, ZHANG F, SHI H J, et al. Extraction and dimensionality reduction of feature vectors in wearable fall detection[J]. *Application Research of Computers*, 2019, 36(1): 103–105.)
- [7] MOSTARAC P, MALARIC R, JURCEVIC M, et al. System for monitoring and fall detection of patients using mobile 3-axis accelerometers sensors[C]// *Proceedings of the 2011 IEEE International Symposium on Medical Measurements and Applications*. Piscataway, NJ: IEEE, 2011: 456–459.
- [8] ZIGEL Y, LITVAK D, GANNOT I. A method for automatic fall detection of elderly people using floor vibrations and sound-proof of concept on human mimicking doll falls[J]. *IEEE Transactions on Biomedical Engineering*, 2009, 56(12): 2858–2867.
- [9] 沈莹, 黎海涛. 基于移动终端的老年人跌倒检测系统设计[J]. *中国新通信*, 2016, 18(7): 13–15. (SHEN Y, LI H T. Design of elderly fall detection system based on mobile terminal [J]. *China New Telecommunication*, 2016, 18(7): 13–15.)
- [10] 王忠民, 张新平, 梁琛. 一种基于时序分析异常数据的跌倒行为监测方法[J]. *计算机应用研究*, 2018, 35(3): 839–843. (WANG Z M, ZHANG X P, LIANG C. A fall behavior monitoring method based on time series analysis abnormal data [J]. *Application Research of Computers*, 2018, 35(3): 839–843.)
- [11] KIANOUSH S, SAVAZZI S, VICENTINI F, et al. Leveraging RF signals for human sensing: fall detection and localization in human-machine shared workspaces[C]// *Proceedings of the 2015 IEEE 13th International Conference on Industrial Informatics*. Piscataway, NJ: IEEE, 2015: 1456–1462.
- [12] KIANOUSH S, SAVAZZI S, VICENTINI F, et al. Device-free RF human body fall detection and localization in industrial workplaces [J]. *IEEE Internet of Things Journal*, 2017, 4(2): 351–362.
- [13] HAN C, WU K, WANG Y, et al. Wifall: device-free fall detection by wireless networks[C]// *INFOCOM 2014: Proceedings of the 2014 IEEE Conference on Computer Communications*. Piscataway, NJ: IEEE, 2014: 271–279.
- [14] WANG Y, WU K, NI L M. WiFall: Device-free fall detection by wireless networks[J]. *IEEE Transactions on Mobile Computing*, 2017, 16(2): 581–594.
- [15] ZHANG D, WANG H, WANG Y, et al. Anti-fall: a non-intrusive and real-time fall detector leveraging CSI from commodity WiFi devices[C]// *ICOST 2015: Proceedings of the 2015 International Conference on Smart Homes and Health Telematics*. Berlin: Springer, 2015: 181–193.
- [16] WANG H, ZHANG D, WANG Y, et al. RT-fall: a real-time and contactless fall detection system with commodity WiFi devices[J]. *IEEE Transactions on Mobile Computing*, 2017, 16(2): 511–526.
- [17] GU Y, ZHAN J, JI Y, et al. MoSense: a RF-based motion detection system via off-the-shelf WiFi devices[J]. *IEEE Internet of Things Journal*, 2017, 4(6): 2326–2341.
- [18] GU Y, LIU T, LI J, et al. EmoSense: data-driven emotion sensing via off-the-shelf WiFi devices[C]// *Proceedings of the 2018 IEEE International Conference on Communications*. Piscataway, NJ: IEEE, 2018: 1–6.

This work is partially supported by the National Natural Science Foundation of China (61772169, 61432004, 61502140), the National Key R&D Program of China (2018YFB0803403), the Fundamental Research Fund for the Central Universities (JZ2018HGPA0272), the Open Project by Jiangsu Province Key Laboratory of Internet of Things (JSWLW-2017-002).

HUANG Mengmeng, born in 1995, M. S. candidate. Her research interests include affective computing, fall detection.

LIU Jun, born in 1978, Ph. D., associate professor. His research interests include machine learning acceleration, computer architecture.

ZHANG Yifan, born in 1993, M. S. candidate. Her research interests include affective computing, machine learning.

GU Yu, born in 1986, Ph. D., professor. His research interest includes affective computing.

REN Fuji, born in 1959, Ph. D., professor. His research interests include affective computing, intelligent robot.